Создание Speech-to-Text анализатора для северномансийского языка: промежуточные результаты

С. Бухарина, М. Сатина, И. Гай

Обработка данных

Немного подробнее о том, с какими данными мы работаем

- Новостные тексты на северномансийском языке (сосьвинский и верхнелозьвинский диалекты)
- Каждый новостной текст содержит 50+ предложений (и обычно ограничивается 100-110 предложениями)
- 6 носителей северномансийского языка (1 мужчина и 5 женщин)
- Тексты озвучены своими авторами
  - Проблема: не удалось установить, какая аппаратура была использована при записи
- Аудиозаписи в течение августа-ноября 2025 г. были размечены на предложения в программе ELAN (**https://archive.mpi.nl/tla/elan**)

Разметка в ELAN

Гайдлайны по разметке →

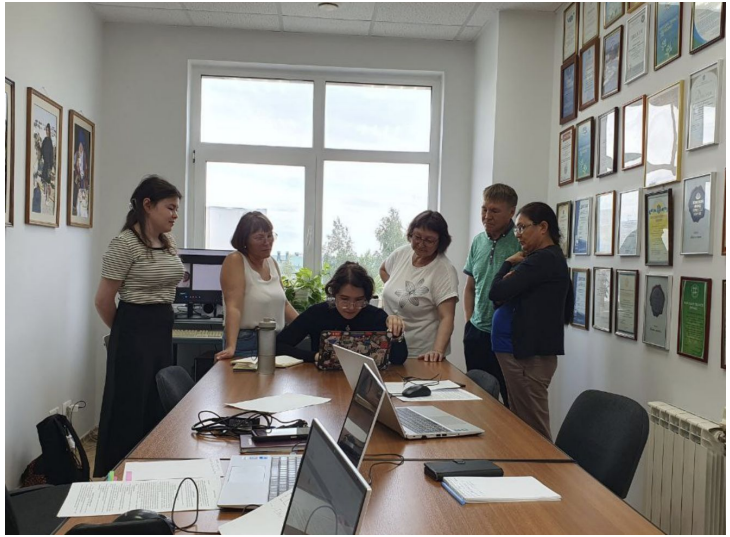

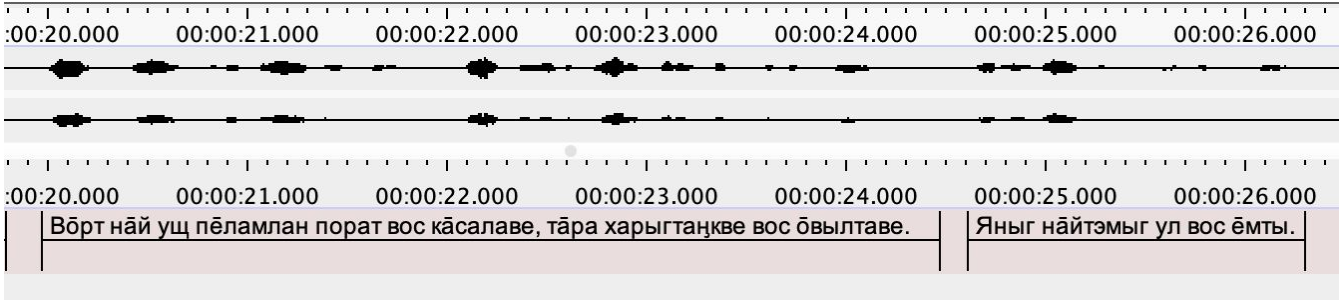

Устранение проблемных мест датасета

- Размеченные тексты хранятся в .eaf-формате
  - Первостепенной задачей было перевести их в формат .wav + .txt (при этом нарезка записей осуществляется по выделенным разметчиками границам фраз) и .json
- Разметка текстов включает в себя знаки препинания и символы разного регистра
  - Отдельной задачей было приведение разметки к нижнему регистру и удаление знаков препинания, поскольку такой формат обычно считается более удачным для ASR
- Было обнаружено несколько непоследовательностей в орфографии у ряда разметчиков
  - Осуществлена унификация графики по литературному графическому стандарту северномансийского языка

Подготовка датасета

- Осуществлена метаразметка носителей, озвучивших рассматриваемые аудиоданные
- 3147 размеченных фраз
- Датасет был разбит на три выборки: train / validation / test
- Пропорция разбиения: 80 / 10 / 10, то есть 2518 / 315 / 314
- При разбиении соблюдался баланс носителей; каждый из 6 авторов текстов представлен в каждой из трёх подвыборок минимум один раз

Выбор моделей

Мультиязычные модели: Wav2vec2-BERT

- Представлена Meta в 2023 г.
- Эволюция оригинальной архитектуры wav2vec 2.0
- Свёрточно-трансформерный энкодер из wav2vec 2.0 извлекает локальные и глобальные акустические паттерны
- BERT-подобный контекстуальный энкодер строит глубокие представления последовательностей
- Предобучение: 4.5 миллиона часов на 143 языках
- На этапе дообучения добавляется CTC-голова, которая помогает избежать необходимость в точном выравнивании по времени
- Наличие адаптеров позволяет получать хорошие результаты для малоресурсных языков

Мультиязычные модели: XLS-R

- Разработана Meta специально для решения задачи трансферного обучения для малых языков
- Архитектура базируется на wav2vec 2.0; предобучение осуществлялось на 123х языках
- Предполагается, что будет давать лучшие показатели при эксперименте с zero-shot
- Предобучение: 436 тысячи часов

Мультиязычные модели: Whisper

- Трансформерная seq2seq модель
- Используется авторегрессивный декодер (вместо CTC-головы)
  - модель естественным образом обрабатывает пунктуацию и капитализацию
- Предобучение: 680 тысяч часов мультиязычных данных
- Показывает высокие результаты с экспериментами в формате zero-shot
- Проблема: токенизатор основан на BPE и обучен на фиксированном словаре из 50,000 субсловных токенов
  - сложность адаптации модели к мансийской графике (расширенной кириллице с достаточно большим количеством специальных символов)

Оффтоп: Потенциальные проблемные места

- В (Ромбандеева 1973: 2) отмечается, что **долгие гласные в северномансийском языке имеют дифтонгический характер**, в то время как краткие гласные монофтонгичны, однако подробно это утверждение в работе не обсуждается.
- В (Алхазова et al. 2026) (in preparation) показано, что все гласные первого слога «претерпевают сильные частотные изменения на протяжении реализации и могут называться фонетическими дифтонгами».
- Интересно, адекватно ли справятся предобученные ASR-модели с таким положением дел.

Модель для уральских языков: Wav2vec2-large-uralic-voxpopuli-v2

- Обучена Meta специально на аудиоданных уральских языков на датасете VoxPopuli
  - записи выступлений в Европейском парламенте на финском, венгерском, эстонском
- Поскольку предобучение осуществлялось на реальных записях речи, модель лучше устойчива к шуму, вариациям дикторов и индивидуальным речевым особенностям
- Архитектурно представляет собой классический wav2vec 2.0 large

Методы

Методы

1. **Zero-Shot:** оценка XLS-R и Whisper на северномансийском без дообучения
2. **DFT** (**Direct Fine-Tuning**)**:** прямое дообучение всех предобученных моделей на малом целевом датасете северномансийского языка
3. **MDFT** (**Merged Dataset Fine-Tuning**)**:** дообучение Wav2vec2-BERT на объединённом датасете (хантыйский + северномансийский / венгерский + северномансийский).
4. **EFT** (Efficient Fine-Tuning)
5. **TFT** (Traditional Fine-Tuning)