Сравнение подходов к созданию Speech-to-Text анализатора для северномансийского языка

С. Бухарина, М. Сатина, И. Гай

Проблема и цель

- **Мансийский язык** (< обско-угорские < финно-угорские < уральские)
- Согласно (Перепись 2020/2021), около 1300 носителей
- **Северная группа** селилась по Северной Сосьве с притоком р. Ляпин, в верховьях рек Лозьвы и Пелыма, вторая — по Конде и её притокам.
- **Южная группа** манси ранее заселяла бассейны Туры, Тавды, среднее течение Камы, Чусовую, верховья р. Уфы.
- **Западная группа** — рек Пелым, Лозьва, Сосьва, Вишера, Колва, Печора и Вычегда.

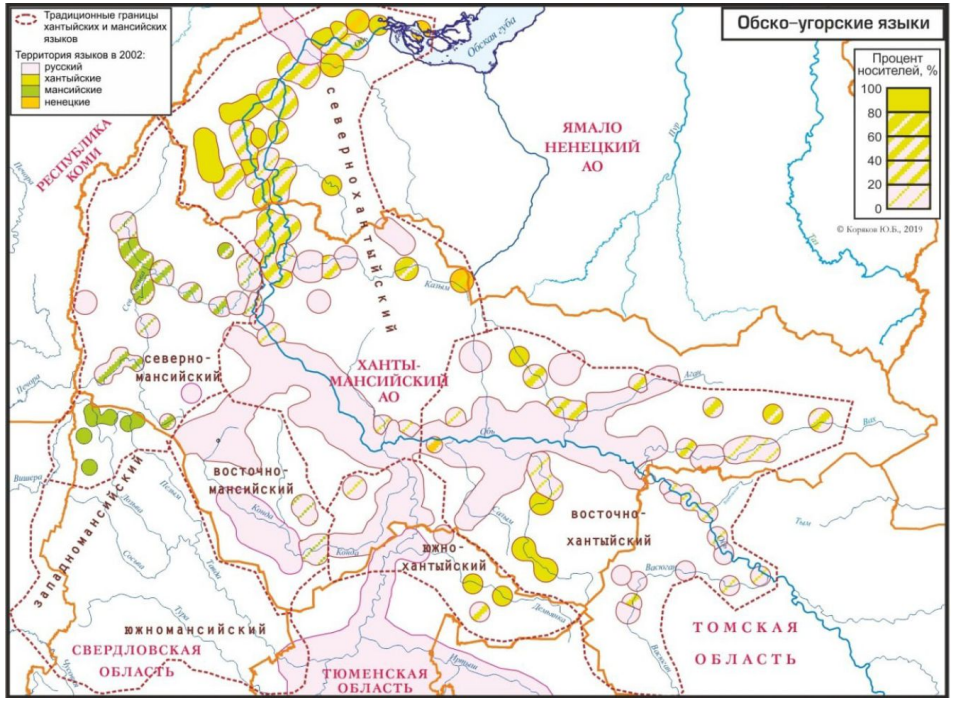

Карта Ю. Корякова

Khanty
Mansi
Hungarian

Почему мы решили работать над инструментами, облегчающими его цифровизацию?

Мансийские идиомы отличаются **последовательной историей документации**:

- 1840-е: Антал Регули
- 1880-е: Бернат Мункачи
- 1900-е: Арттури Каннисто
- 1930-е: Валерий Чернецов, материалы Московской консерватории
- 1950-е и далее: Евдокия Ромбандеева
- множество современных материалов

⊕ Записи новостей ГТРК Югория, аудиоархив газеты “Лӯима Сэ̄рипос”, многочисленные экспедиционные записи

Почему мы решили работать над инструментами, облегчающими его цифровизацию?

НО: несмотря на последовательную историю документации, наблюдаем **digital enganderment** (Abney 2011).

<<For computational linguistics, data that is not publicly available might as well not exist, and languages without publicly available data receive no attention. This is to the detriment not only of technology development in those languages, but also to the detriment of their effective preservation.>>

Почему мы решили работать над инструментами, облегчающими его цифровизацию?

Работу над архивными данными нужно начинать своевременно, так как для их обработки часто требуется активное включение носителей языка.

<<…we need to increase the rate at which language data is collected. The best hope for that is by **enlisting help outside of linguistics**.>>

<<…**crowd-sourcing is a promising mechanism** for getting more people involved.>>

Данные

Архив газеты Лӯима Сэ̄рипос

- Новостные тексты на северномансийском языке (сосьвинский и верхнелозьвинский диалекты)
- Каждый новостной текст содержит 50+ предложений (и обычно ограничивается 100-110 предложениями)
- 6 носителей северномансийского языка (1 мужчина и 5 женщин)
- Тексты озвучены своими авторами
  - Проблема: не удалось установить, какая аппаратура была использована при записи
- Аудиозаписи в течение августа-ноября 2025 г. были размечены на предложения в программе ELAN (**https://archive.mpi.nl/tla/elan**)

Архив газеты Лӯимӑ сӑрипос

№ 1 (1235) 2021

№ 14 (1248) 2021

№ 15 (1249) 2021

№ 16 (1250) 2021

Разметка в ELAN

Гайдлайны по разметке →

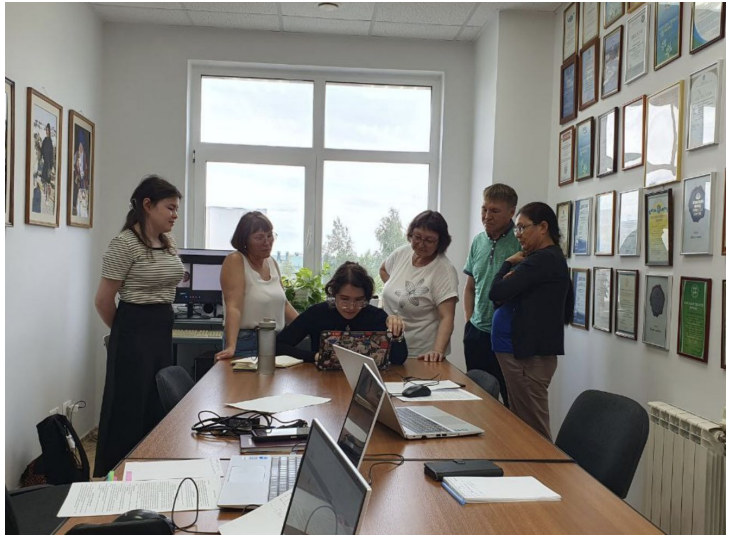

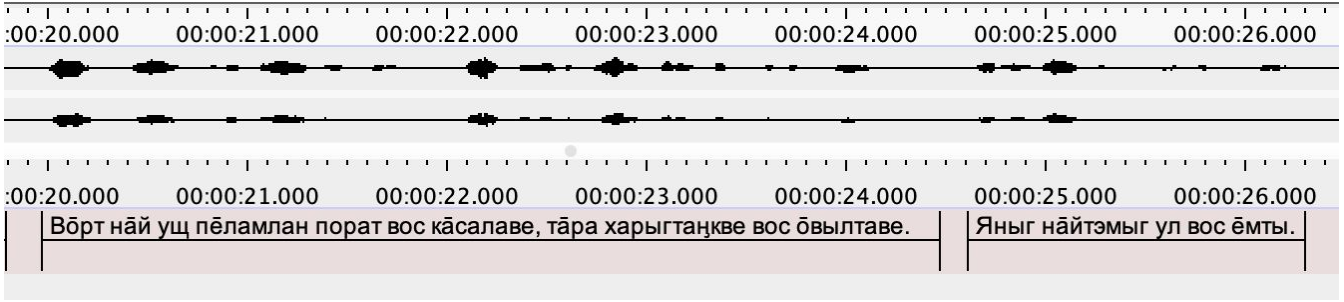

Решения для других малоресурсных языков

Transliteration-Aided Transfer Learning for Low-Resource ASR: A Case Study on Khalkha Mongolian

Статья посвящена улучшению систем автоматического распознавания речи (ASR) для низкоресурсного халха-монгольского языка. Авторы предлагают метод трансферного обучения с помощью транслитерации: датасет близкородственного, но лучше обеспеченного ресурсами чахар-монгольского языка (в старомонгольской письменности) транслитерируется на кириллицу и используется для дообучения ASR-модели. Затем модель дообучается на малом целевом датасете халха-монгольского языка. Метод проверен на трёх популярных ASR-моделях Wav2Vec2-BERT, Conformer-Large и Whisper-large-v3 и показал значительное улучшение: относительное снижение Word Error Rate (WER) до 32.5%.

Методология: двухэтапный подход

1. Транслитерация: текстовая часть датасета чахар-монгольского языка (старомонгольское письмо) транслитерируется в кириллицу. Задача не просто побуквенной замены, а учёта фонетических правил, редукции гласных, гармонии гласных, выпадения/добавления букв и различий в лексике (заимствования из китайского против заимствований из русского). В результате получается новый датасет с той же аудиочастью (чахарское произношение), но с текстом на кириллице.

Traditional word	Syllable	Cyrillic word	Syllable	Variation
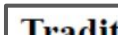	xele	ХЭЛ	xel	The 2nd “э” is dropped
	ang-un	АНГИЙН	ang-giin	Additional consonant “g” sound.
	o-lan	ОЛОН	o-lon	Vowel harmony. “la” changed to “lo”.
	xo-yar	ХОЁР	xo-yor	Vowel harmony, “ya” changed to “yo”
	mong-gol-yier	МОНГОЛООР	mon-go-loor	Vowel harmony, “yier” changed to “oor”

Методология: двухэтапный подход

2. Двухэтапное дообучение:

2.1. Extended Fine-Tuning (EFT): предобученная модель сначала дообучается на полученном транслитерированном датасете. Это позволяет модели научиться сопоставлять монгольскую речь (однако с чахарским акцентом) с кириллическим текстом.

2.2. Targeted Fine-Tuning (TFT): полученная на первом этапе модель далее дообучается на очень маленьком целевом датасете халха-монгольского языка, чтобы адаптироваться к особенностям произношения и лексики именно этого диалекта.

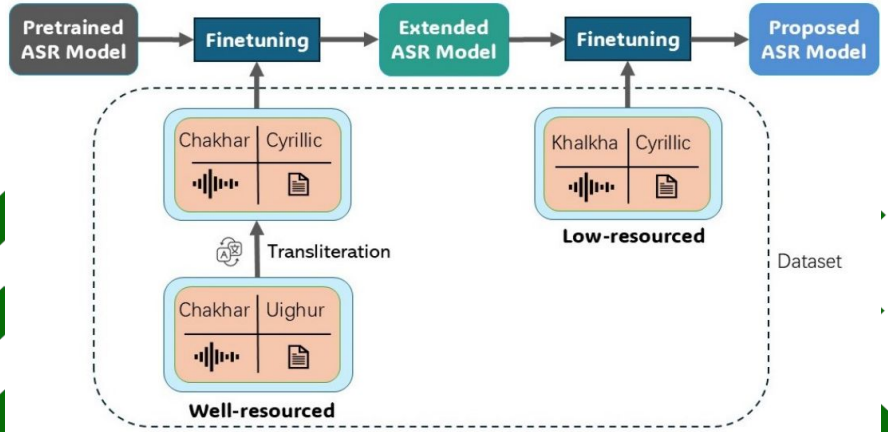

Эксперимент

Модели и данные	Методы
Использовались три предобученные ASR-модели: Wav2Vec2-BERT, Whisper-large-v3 (многоязычные) и Conformer-Large (англоязычная). Данные для EFT: транслитерированный датасет M2ASR-MONGO (чахарский диалект, ~147 часов). Данные для TFT: малый датасет халха-монгольского языка из Common Voice v17 (~3 часа).	Zero-Shot: оценка Whisper-large-v3 на халха-монгольском без дообучения. DFT (Direct Fine-Tuning): прямое дообучение всех трёх предобученных моделей на малом целевом датасете халха-монгольского (Common Voice). MDFT (Merged Dataset Fine-Tuning): дообучение на объединённом датасете (транслитерированный M2ASR + Common Voice). EFT TFT

Результаты

1. Zero-Shot показал ожидаемо высокие ошибки (CER 45.73%, WER 92.60%).
2. DFT дал улучшение, но результаты были скромными из-за малого объёма данных. Лучшей была Whisper (CER 13.96%, WER 43.02%).
3. MDFT неожиданно лучше всех сработал для Conformer (CER 16.12%, WER 43.01%), но ухудшил результаты для других моделей, вероятно, из-за смешения диалектов.
4. EFT показало наихудшие результаты на целевом тесте из-за различий диалектов, записи и лексики.
5. TFT показал наилучшие результаты для всех моделей. Whisper-large-v3 достигла CER 10.75% и WER 31.45% .
6. Анализ ошибок показывает, что TFT систематически снижает количество вставок, удалений и замен символов по сравнению с DFT.
7. Сравнение кривых обучения демонстрирует, что TFT позволяет быстрее и сильнее снизить ошибку на валидации, чем DFT.

Towards a Speech Recognizer for Komi, an Endangered and Low-Resource Uralic Language

- В статье представлена первая версия модели распознавания речи для коми языка.
- Сравниваются подход transfer learning на основе английского языка и baseline-модель, обученная с нуля с использованием системы DeepSpeech (обычно применяемая для языков с большими ресурсами).
- Цель — не полная автоматизация, а ускорение расшифровки, чтобы исследователь исправлял ошибки, а не набирал текст вручную.

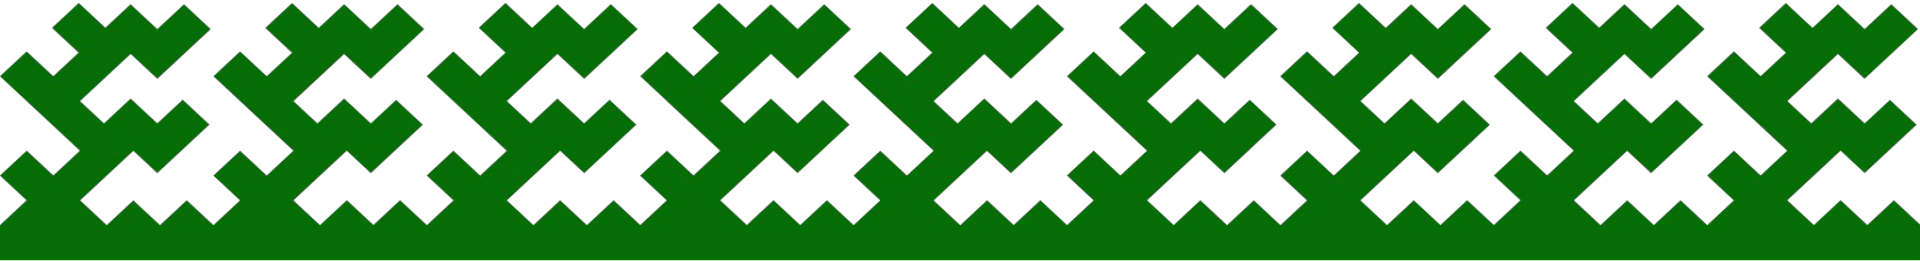

Использованные ресурсы

1. Корпус устной коми речи: включает около 35 часов расшифрованных интервью и разговоров от более чем 200 дикторов. Транскрипция выполнена носителями языка и очень подробна.
2. DeepSpeech — рекуррентная нейросеть (LSTM) для распознавания речи. Важной частью является языковая модель (на базе KenLM), которая корректирует выходные данные нейросети на основе вероятности тех или иных последовательностей слов. Гиперпараметры α (влияние языковой модели) и β (вставка пробелов) настраиваются отдельно.

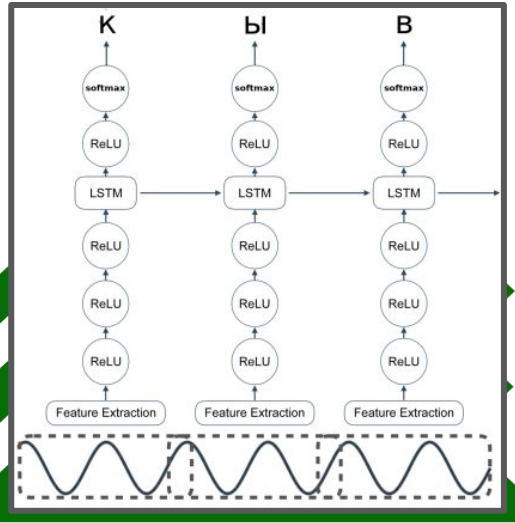

Эксперимент и результаты

Данные были разделены на обучающую, тестовую и проверочную выборки (80/10/10). Были обучены две модели: baseline (с нуля) и модель с трансферным обучением (на основе предобученной английской модели). Языковая модель для коррекции вывода была обучена на большом текстовом корпусе коми языка (книги, газеты) для большей мощности. Параметры языковой модели α и β отдельно настраивались для улучшения результата. Для оценки влияния языковой модели их отключали (α=0, β=0).

Лучший результат показала модель с трансферным обучением (CER 70.9%, WER 100%) при отключенной языковой модели. Настройка языковой модели улучшала baseline модель, но не помогала трансферной. Ни одна модель не смогла точно распознать ни одного полного слова (WER 100%). Меньшее влияние языковой модели (=низкий α) даёт лучшие результаты.

System	CER (%)	WER (%)
Baseline	82.7	99.1
Transfer tuned	72.1	100.0
Transfer baseline	82.9	**98.3**
Baseline tuned lm	73.8	100.0
Baseline no lm	72.7	100.0
Transfer no lm	**70.9**	100.0

		beta				
	CER/WER	1	3	5	7	9
alpha	0.25	77.3/100.0	74.9/100.0	**73.8**/100.0	74.5/100.0	78.2/100.0
	0.5	80.7/100.0	77.7/100.0	75.2/100.0	74.3/100.0	75.0/100.0
	0.75	84.1/**98.6**	80.7/100.0	77.8/100.0	75.7/100.0	74.8/100.0

Table 3: The impact of tuning the language model parameters on Character and Word Error Rates for the baseline model.

		beta				
	CER/WER	1	3	5	7	9
alpha	0.25	76.6/100.0	73.2/100.0	**72.1**/100.0	74.0/100.0	81.8/100.0
	0.5	81.0/99.4	77.0/100.0	74.0/100.0	73.3/100.0	75.8/100.0
	0.75	85.2/**98.1**	80.1/100.0	77.2/100.0	74.8/100.0	74.7/100.0

Table 4: The impact of tuning the language model parameters on Character and Word Error Rates for the transfer learning model.

Выводы

1. Система хорошо распознаёт только короткие и простые слова, что указывает на возможный дисбаланс классов в данных. Возможные решения: увеличить минимальную длину аудиоклипов или отбирать данные только от основных дикторов. Языковая модель в текущем виде скорее мешает, так как её данные стилистически неоднородны.
2. Технологию можно интегрировать в работу лингвиста: лингвист вручную размечает отрезки в ELAN, а внешний скрипт отправляет их в систему распознавания и возвращает предварительную расшифровку.
3. Необходимо повторить эксперимент с другими системами распознавания речи и на других языках, чтобы понять, связаны ли проблемы с особенностями коми корпуса или с архитектурой DeepSpeech.

Low-Resource ASR with an Augmented Language Model

- Статья посвящена улучшению автоматического распознавания речи (ASR) для бесписьменного бесермянского наречия (диалект удмуртского языка).
- Основная проблема: для языка есть всего ~10 часов аудио и ~164 000 слов текста. Этого достаточно для обучения ASR, но крайне мало для создания хорошей языковой модели, критически важной для качества распознавания.
- Лучшая baseline модель DeepSpeech показывает WER 56.4% .
- Для бесермянского существуют дополнительные лингвистические ресурсы: бесермянско-русский словарь (~6000 статей) и морфологический анализатор, который покрывает ~97% слов корпуса.

Augmented Language Model

Цель: использовать эти дополнительные ресурсы для искусственного расширения текстового корпуса и улучшения языковой модели и, как следствие, качества ASR.

Решение: разработать генератор предложений, который создаёт новые, но правдоподобные фразы, сохраняя частотность лемм, частотность аффиксов, грамматические ограничения, лексическую сочетаемость. Для этого реальные предложения превращаются в шаблоны. Знаменательные части речи заменяются на «слоты» с информацией о грамматических признаках и аффиксах, служебные слова остаются. Из морфологического анализатора загружаются все леммы, их основы и грамматические теги. Для лемм из корпуса сохраняется их реальная частотность, для остальных частота = 1. Для существительных, глаголов и прилагательных создаются матрицы семантических соседей на основе их русских переводов из двуязычного словаря. Близость вычисляется с помощью эмбеддингов русских слов.

Эксперимент

Базовый ASR-инструмент DeepSpeech:

- 5-слойная нейросеть с одним LSTM-слоем
- Вход: аудио 16 кГц, моно
- Выход фильтруется n-граммной KenLM

	$\beta = 1$	$\beta = 2$	$\beta = 3$	$\beta = 4$
$\alpha = 1.0$	57.3 / 55.6	56.5 / 54.1	57.7 / 52.7	58.8 / 52.4
$\alpha = 0.9$	57.0 / 53.3	56.8 / 52.7	58.4 / 51.6	59.6 / 53.5
$\alpha = 0.75$	56.4 / 52.9	57.2 / 51.9	58.7 / **51.4**	60.9 / 53.4
$\alpha = 0.6$	57.1 / 52.9	58.9 / 51.9	60.4 / 53.8	64.9 / 56.3
$\alpha = 0.4$	59.6 / 55.5	62.3 / 56.4	67.0 / 59.8	75.4 / 66.1

Table 1: WER for base (before slash) and gen (after slash) models with different α and β values.

Данные для обучения ASR:

- ~10 часов выровненной речи из корпуса бесермянского
- +2.5 часа из звукового словаря (по 3 произношения на заглавное слово)
- Транскрипция в UPA (один символ = один звук, CER ≈ PER)

	$\beta = 1$	$\beta = 2$	$\beta = 3$	$\beta = 4$
$\alpha = 1.0$	35.0 / 34.4	33.9 / 33.3	33.3 / 32.0	32.8 / 30.9
$\alpha = 0.9$	34.0 / 32.5	33.4 / 32.1	33.0 / 30.7	32.7 / 30.2
$\alpha = 0.75$	32.9 / 31.5	32.4 / 30.4	32.0 / 29.7	31.9 / **29.2**
$\alpha = 0.6$	32.2 / 30.1	31.5 / 29.9	31.5 / 29.6	31.7 / 29.3
$\alpha = 0.4$	31.6 / 30.1	31.3 / 29.6	31.3 / 30.3	31.8 / 30.8

Table 2: CER for base (before slash) and gen (after slash) models with different α and β values.

Результаты

1. Дополненная модель стабильно превосходит базовую при всех значениях гиперпараметров.
2. Эффект сильнее на длинных предложениях:
   Для предложений с ≥6 словами: лучший WER базовой — 59.5%, дополненной — 52.1%.
   Для коротких предложений (≤3 слова): разница минимальна (61.5% vs 60.5%).
3. Ключевой компонент — семантическая близость: эксперименты показали, что без использования эмбеддингов русских переводов для поиска семантических соседей улучшения не происходит.
4. Увеличение объёма сгенерированных предложений с 2 млн до 10 млн почти не дало прироста качества.
5. Предложенный метод генерации позволяет создать более мощную языковую модель, что даёт измеримое, хотя и скромное, улучшение WER (на 5%). Однако итоговая модель всё ещё далека от практического использования (WER 51.4%).

План

1. Изучить причины, по которым существующие решения для других малоресурсных языков являются удачными или неудачными.

2. Выявить потенциально лучшие из них для северномансийского языка, основываясь на лингвистических характеристиках языка, параметрах доступных данных и свойствах подходов к созданию Speech-to-Text анализатора.

3. Сравнить их по параметрам качества и применимости.

4. (Попробовать создать своё решение).